Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Направление подготовки
“01.03.02. Прикладная математика и информатика”

Дисциплина “Математическая статистика”

Отчет по лабораторной работе №3
Боксплот Тьюки и анализ выбросов

Работу выполнил:
Никоноров А.К.
Группа: 5030102/30201
Преподаватель:
Баженов А.Н.

Санкт-Петербург
2026

Содержание

1. Постановка задачи ... 3
2. Теоретическая часть ... 3
   2.1. Общие формулы ... 4
   2.2. Нормальное распределение $N(0,1)$ ... 4
   2.3. Распределение Коши $C(0,1)$ ... 4
   2.4. Распределение Лапласа $L\left(0, \frac{1}{\sqrt{2}}\right)$ ... 4
   2.5. Распределение Пуассона $P(10)$ ... 5
   2.6. Равномерное распределение $U\left(-\sqrt{3}, \sqrt{3}\right)$ ... 5
   2.7. Сводная таблица теоретических значений ... 6
3. Реализация ... 6
4. Результаты ... 7
5. Обсуждение ... 10
6. Выводы ... 10
7. Список литературы ... 11
8. Приложение ... 11

1. Постановка задачи

- Сгенерировать выборки объёмом n = 20, 100. Построить боксплот Тьюки.
- Определить долю выбросов экспериментально: для каждого распределения сгенерировать 1000 выборок заданного объёма, вычислить среднюю долю выбросов.

2. Теоретическая часть

- Боксплот - график, использующийся в описательной статистике, компактно изображающий одномерное распределение вероятностей.

1. Первый квартиль (Q1)

$$z_{\frac{1}{4}} = x_{(l)}, \quad l = \lceil 0.25 * n \rceil$$

2. Третий квартиль (Q3)

$$z_{\frac{3}{4}} = x_{(m)}, \quad m = \lceil 0.75 * n \rceil$$

3. Межквартильный размах (IQR)

$$\mathrm{IQR} = z_{\frac{3}{4}} - z_{\frac{1}{4}}$$

4. Нижняя граница выбросов

$$L = z_{\frac{1}{4}} - 1.5 * \mathrm{IQR}$$

5. Верхняя граница выбросов

$$U = z_{\frac{3}{4}} + 1.5 * \mathrm{IQR}$$

6. Выбросы

x_i - выброс, если $x_i < L$ или $x_i > U$

Боксплот Тьюки является графическим инструментом для визуализации распределения данных и обнаружения аномальных значений. В данной работе исследуется доля выбросов при различных объёмах выборки и распределениях.

- **Первый квартиль (Q1)** - значение, ниже которого находится 25% элементов выборки
- **Третий квартиль (Q3)** - значение, ниже которого находится 75% элементов выборки
- **Межквартильный размах (IQR)** - мера рассеяния, охватывающая центральные 50% данных
- **Границы выбросов** - определяются через правило $1.5 * \mathrm{IQR}$, предложенное Тьюки
- **Выбросы** - наблюдения, выходящие за пределы допустимого диапазона [L, U]

  - **Для каждого распределения получим теоретические значения квартилей, межквартильного размаха и границ выбросов.**

Для каждого распределения вычислим теоретические значения квартилей, межквартильного размаха и границ выбросов.

2.1. Общие формулы

$$Q_1 = F^{-1}(0.25), \quad Q_3 = F^{-1}(0.75), \quad \mathrm{IQR} = Q_3 - Q_1$$

$$L = Q_1 - 1.5 * \mathrm{IQR}, \quad U = Q_3 + 1.5 * \mathrm{IQR}$$

2.2. Нормальное распределение $N(0,1)$

$$Q_1 = \Phi^{-1}(0.25) \approx -0.6745$$

$$Q_3 = \Phi^{-1}(0.75) \approx 0.6745$$

$$\mathrm{IQR} = 2 * 0.6745 \approx 1.3490$$

$$L = -0.6745 - 1.5 * 1.3490 \approx -2.6980$$

$$U = 0.6745 + 1.5 * 1.3490 \approx 2.6980$$

Теоретическая доля выбросов:

$$p_{\text{out}} = 2 * (1 - \Phi(2.6980)) \approx 0.0070$$

или примерно 0.70%.

2.3. Распределение Коши $C(0,1)$

Функция распределения:

$$F(x) = \frac{1}{2} + \frac{1}{\pi} * \arctan(x)$$

$$Q_1 : F(Q_1) = 0.25 \Rightarrow \arctan(Q_1) = -\frac{\pi}{4} \Rightarrow Q_1 = -1$$

$$Q_3 : F(Q_3) = 0.75 \Rightarrow \arctan(Q_3) = \frac{\pi}{4} \Rightarrow Q_3 = 1$$

$$\mathrm{IQR} = 1 - (-1) = 2$$

$$L = -1 - 1.5 * 2 = -4$$

$$U = 1 + 1.5 * 2 = 4$$

Теоретическая доля выбросов:

$$p_{\text{out}} = 2 * (1 - F(4)) = 1 - \frac{2}{\pi} * \arctan(4) \approx 0.1560$$

2.4. Распределение Лапласа $L\left(0, \frac{1}{\sqrt{2}}\right)$

Функция распределения:

$$F(x) = \frac{1}{2} * \exp\left(x * \sqrt{2}\right), x < 0; 1 - \frac{1}{2} * \exp\left(-x * \sqrt{2}\right), x \geq 0)$$

$$Q_1 : \frac{1}{2} * \exp\left(Q_1 * \sqrt{2}\right) = 0.25 \Rightarrow Q_1 = -\frac{\ln(2)}{\sqrt{2}} \approx -0.4901$$

$$Q_3 : 1 - \frac{1}{2} * \exp\left(-Q_3 * \sqrt{2}\right) = 0.75 \Rightarrow Q_3 = \frac{\ln(2)}{\sqrt{2}} \approx 0.4901$$

$$\mathrm{IQR} = 2 * \frac{\ln(2)}{\sqrt{2}} = \sqrt{2} * \ln(2) \approx 0.9803$$

$$L = -\frac{\ln(2)}{\sqrt{2}} - 1.5 * \sqrt{2} * \ln(2) = -2 * \sqrt{2} * \ln(2) \approx -1.9605$$

$$U = \frac{\ln(2)}{\sqrt{2}} + 1.5 * \sqrt{2} * \ln(2) = 2 * \sqrt{2} * \ln(2) \approx 1.9605$$

Теоретическая доля выбросов:

$$p_{\text{out}} = \exp(-4 * \ln(2)) = \frac{1}{16} = 0.0625$$

2.5. Распределение Пуассона $P(10)$

Дискретное распределение с параметром $\lambda = 10$.

Квантиль определим как:

$$Q_p = \min_{k \in \mathbb{Z}} \{k : F(k) \geq p\}$$

$$Q_1 = 8$$

$$Q_3 = 12$$

$$\mathrm{IQR} = 12 - 8 = 4$$

$$L = 8 - 1.5 * 4 = 2$$

$$U = 12 + 1.5 * 4 = 18$$

Теоретическая доля выбросов:

$$p_{\text{out}} = P(X \leq 1) + P(X \geq 19) \approx 0.0077$$

2.6. Равномерное распределение $U\left(-\sqrt{3}, \sqrt{3}\right)$

Для равномерного распределения на отрезке $[a, b]$:

$$Q_1 = a + 0.25 * (b - a) = \frac{3a + b}{4}$$

$$Q_3 = a + 0.75 * (b - a) = \frac{a + 3b}{4}$$

$$\mathrm{IQR} = 0.5 * (b - a)$$

$$L = Q_1 - 1.5 * \mathrm{IQR} = \frac{3a - b}{2}$$

$$U = Q_3 + 1.5 * \mathrm{IQR} = \frac{-a + 3b}{2}$$

Для $a = -\sqrt{3}$ и $b = \sqrt{3}$:

$$Q_1 = -\frac{\sqrt{3}}{2} \approx -0.8660$$

$$Q_3 = \frac{\sqrt{3}}{2} \approx 0.8660$$

$$\mathrm{IQR} = \sqrt{3} \approx 1.7321$$

$$L = -2 * \sqrt{3} \approx -3.4641$$

$$U = 2 * \sqrt{3} \approx 3.4641$$

Теоретическая доля выбросов:

$$p_{\text{out}} = 0$$

2.7. Сводная таблица теоретических значений

Распределение	$\boldsymbol{Q_1}$	$\boldsymbol{Q_3}$	**IQR**	$\boldsymbol{L}$	$\boldsymbol{U}$	$\boldsymbol{p_{\text{out}}}$
$N(0,1)$	-0.674	0.674	1.349	-2.698	2.698	0.0070
$C(0,1)$	-1	1	2	-4	4	0.1560
$L\left(0, \frac{1}{\sqrt{2}}\right)$	-0.490	0.490	0.980	-1.961	1.961	0.0625
$P(10)$	8	12	4	2	18	0.0077
$U\left(-\sqrt{3}, \sqrt{3}\right)$	-0.866	0.866	1.732	-3.464	3.464	0

3. Реализация

Лабораторная работа выполнена с помощью языка программирования Python 3.14.0 в среде разработки Visual Studio Code.
Используемые библиотеки: numpy, matplotlib, scipy, pandas

4. Результаты

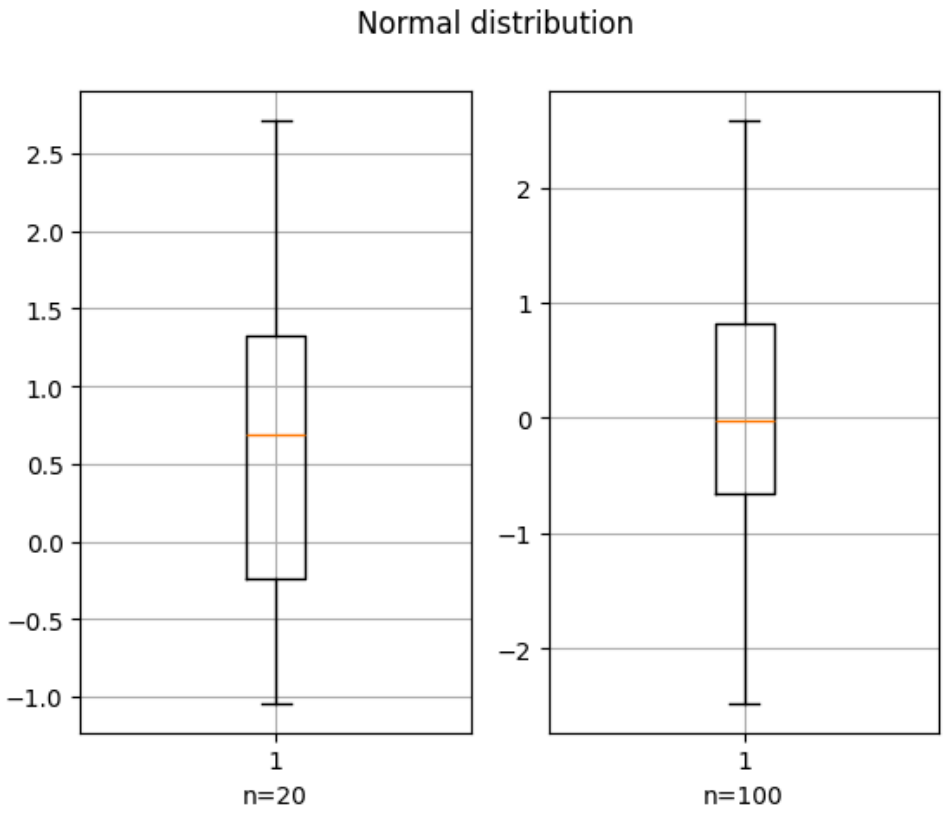

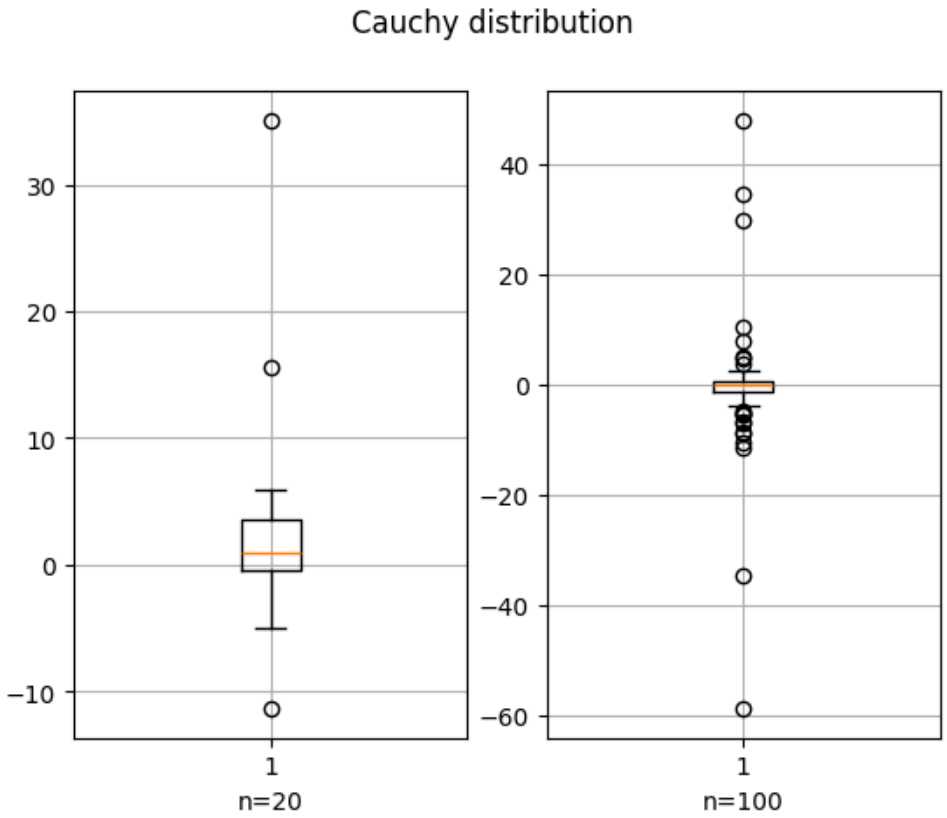

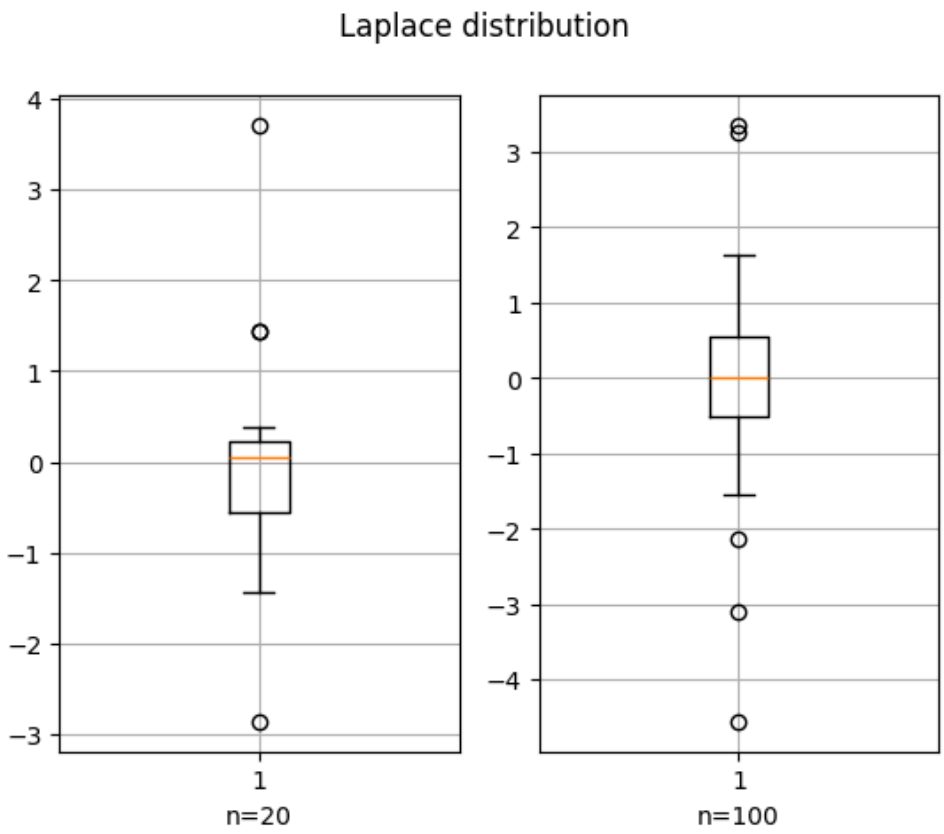
Laplace distribution
4
3
2
1
0
−1
−2
−3
1
n=20
3
2
1
0
−1
−2
−3
−4
1
n=100

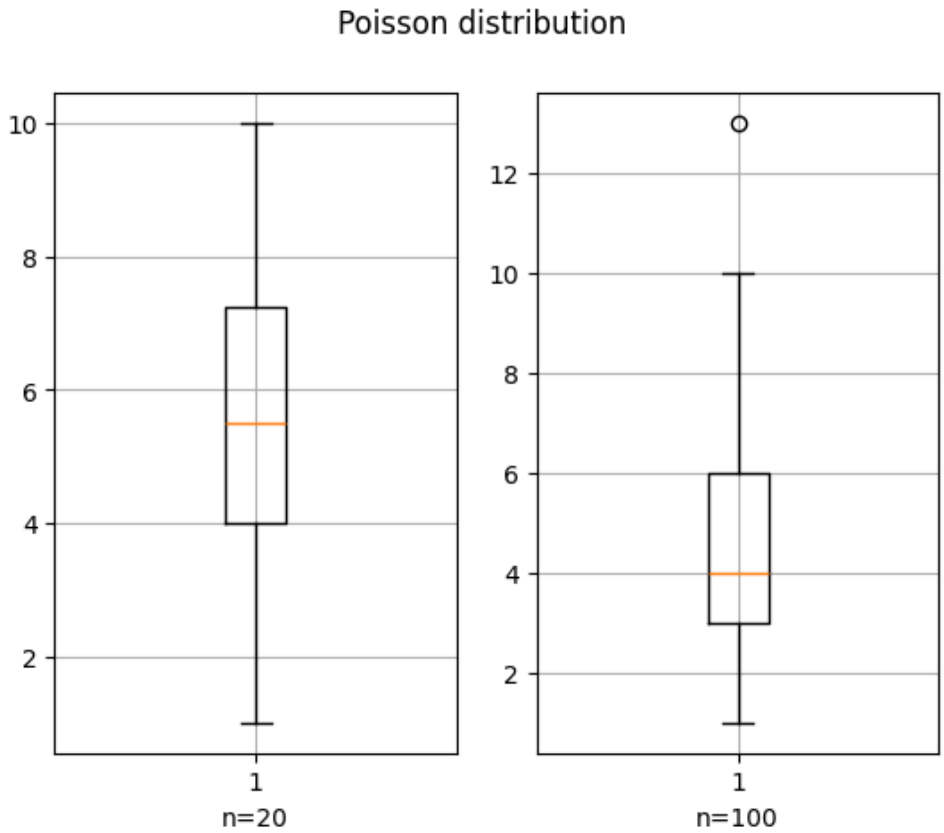
Poisson distribution
10
8
6
4
2
1
n=20
12
10
8
6
4
2
1
n=100

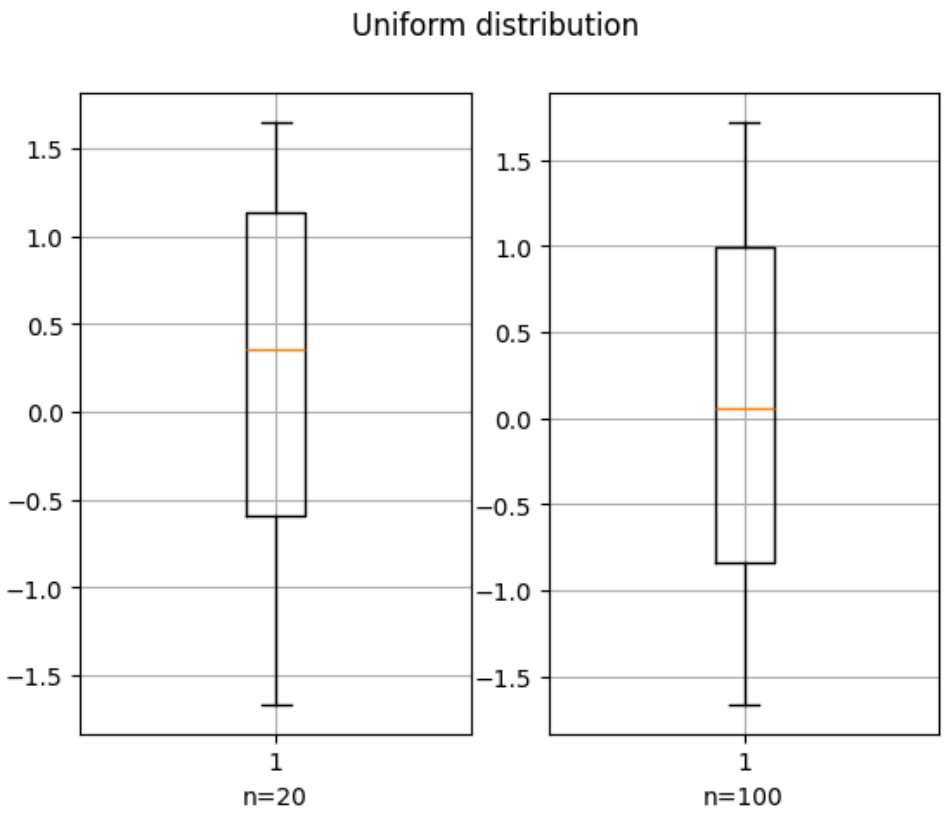

Средняя доля выбросов (1000 повторений):

- Normal
  n=20: 0.0232
  n=100: 0.0104
- Cauchy
  n=20: 0.1545
  n=100: 0.1543
- Laplace
  n=20: 0.0754
  n=100: 0.0649
- Poisson
  n=20: 0.0251
  n=100: 0.0108
- Uniform
  n=20: 0.0025
  n=100: 0.0000

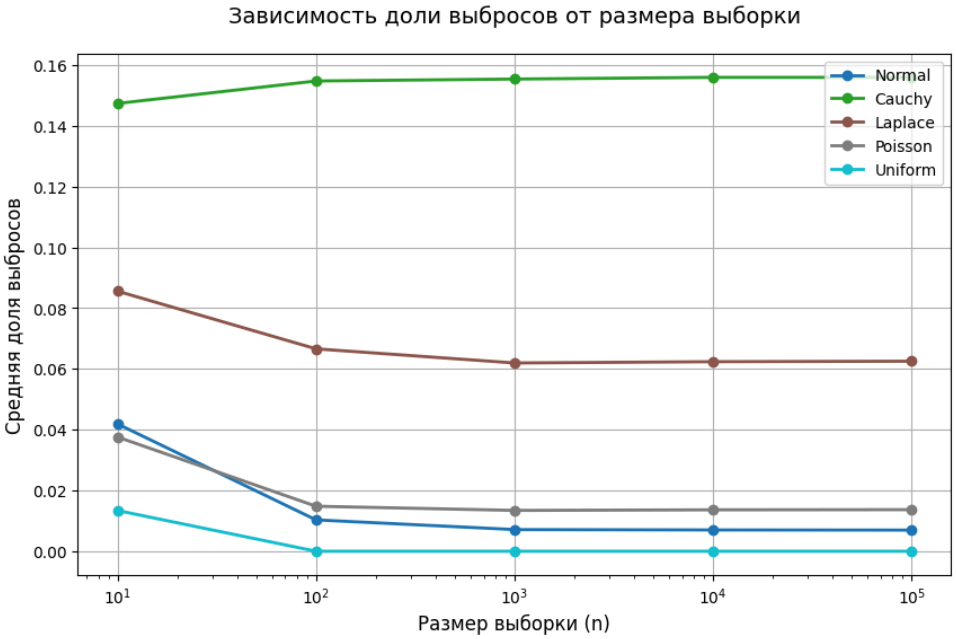

5. Обсуждение

В ходе выполнения работы были исследованы боксплоты Тьюки и доли выбросов для пяти распределений для выборок объёмом $n = 20$ и $n = 100$.

Исходя из полученных результатов, можно сделать вывод о том, что при увеличении n гистограмма все ближе к графику теоретической кривой плотности.

- **Нормальное распределение:** Экспериментальная доля выбросов при $n = 20$ превышает теоретическую в 3.3 раза, однако при $n = 100$ разница сокращается до 1.5 раз. Это объясняется тем, что при малых объёмах выборки оценка квартилей менее точна, что приводит к расширению границ усов и большему количеству ложных выбросов
- **Распределение Коши**: Результаты наиболее близки к теоретическим значениям уже при $n = 20$ и практически не меняются при увеличении выборки.
- **Распределение Лапласа**:Наблюдается хорошая сходимость к теоретическому значению 0.0625. При $n = 100$ экспериментальная доля 0.0649 отличается от теории менее чем на 4%.
- **Распределение Пуассона**: Дискретность распределения влияет на точность определения квартилей. При $n = 100$ наблюдается согласование с теорией.
- **Равномерное распределение**: Теоретически выбросов быть не должно, так как распределение ограничено. Экспериментально при $n = 100$ получено 0, что подтверждает теорию. При $n = 20$ небольшая доля 0.0025 объясняется случайными колебаниями границ квартилей.

6. Выводы

1) С увеличением размера выборки оценка доли становится стабильнее.
2)Доля выявляемых выбросов зависит от свойств распределения:

- Для распределений с лёгкими хвостами (нормальное, равномерное) доля выбросов мала
- Для распределений с тяжёлыми хвостами (Коши, Лаплас) выбросы являются естественной частью данных

7. Список литературы

- Боровков А.А. “Математическая статистика”
- Бабахина С.А., Баженов А. Н. “Практикум по математической статистике: учебное пособие”

8. Приложение

https://github.com/akkniko/math-statistic/tree/master/lab3